机器学习

实验报告

2023–2024 学年　第二学期

学　　院：数学与统计学院

班　　级：数学强基 2301

学　　号：2233210080

姓　　名：袁浩然

指导教师：孟德宇老师

实验地点：数学实验中心

实验四：PCA 算法消除噪声

一、问题描述

本次实验构造一个包含噪声的 4 维数据集，目标是利用 PCA 方法尽可能保留主要有效信息、压制随机噪声影响，并观察降噪前后数据质量变化。题目要求尽量不要直接调用现成 PCA 算法，因此本实验采用 NumPy 手写 PCA 的方式完成。

实验主要任务包括：

1. 准备含噪数据；
2. 手写 PCA 并提取主成分；
3. 用低维表示重建原始数据实现降噪；
4. 对比降噪前后的可视化与指标结果。

二、算法原理

PCA 的核心思想是将原始特征空间旋转到一组正交基上，使数据在前几个方向上具有最大方差。通常噪声更容易分散在小方差方向上，因此保留主要主成分并进行重建可以达到降噪目的。

设标准化后的数据为 $X \in \mathbb{R}^{n\times d}$，其协方差矩阵为：

$$\Sigma = \frac{1}{n-1} X^T X$$

对 Σ 做特征分解，得到特征值与特征向量。将特征值从大到小排序后，取前 k 个特征向量组成投影矩阵 W_k，则：

$$Z = XW_k$$

为低维表示；再做反变换：

$$\hat{X} = ZW_k^T$$

可得到去噪后的重建结果。

本实验中原始数据是 4 维，降到 2 维（$k = 2$）后再重建，观察降噪效果。另外，我对 PCA 原始论文进行了复现，复现笔记同样放在文件夹中。

三、实验步骤与实现细节

1. 先构造 2 个潜在变量，并线性组合成 4 维“干净数据”；
2. 在每个特征上叠加高斯噪声，得到含噪数据；
3. 对含噪数据做标准化；
4. 手写 PCA：协方差矩阵、特征分解、排序选主成分；
5. 将数据投影到前 2 个主成分，再逆变换到原空间得到去噪数据；
6. 用 MSE 和逐特征相关系数评估去噪效果；
7. 绘制三类图：数据对比散点图、方差贡献率图、相关系数对比图。

四、核心代码

下面给出核心实现片段。完整代码包含数据生成、评估和可视化。

```python
class PCAFromScratch:
    def __init__(self, n_components=2):
        self.n_components = n_components
        self.mean_ = None
        self.components_ = None
        self.eigenvalues_ = None
        self.explained_variance_ratio_ = None

    def fit(self, x):
        self.mean_ = np.mean(x, axis=0)
        x_centered = x - self.mean_
        cov = np.dot(x_centered.T, x_centered) / (x_centered.shape[0] - 1)
        eigenvalues, eigenvectors = np.linalg.eigh(cov)

        sorted_indices = np.argsort(eigenvalues)[::-1]
        eigenvalues = eigenvalues[sorted_indices]
        eigenvectors = eigenvectors[:, sorted_indices]

        self.eigenvalues_ = eigenvalues
        self.components_ = eigenvectors[:, : self.n_components]
        self.explained_variance_ratio_ = eigenvalues / np.sum(eigenvalues)
```

```python
        return self

    def transform(self, x):
        x_centered = x - self.mean_
        return np.dot(x_centered, self.components_)

    def inverse_transform(self, z):
        return np.dot(z, self.components_.T) + self.mean_

def main():
    x_clean, x_noisy = generate_noisy_dataset(n_samples=200, random_state
        =7)
    scaler = StandardScaler()
    x_noisy_std = scaler.fit_transform(x_noisy)

    pca = PCAFromScratch(n_components=2)
    z = pca.fit_transform(x_noisy_std)
    x_recon_std = pca.inverse_transform(z)
    x_denoised = scaler.inverse_transform(x_recon_std)
```

五、实验结果与分析

实验运行后，含噪数据经过 PCA 降维重建得到去噪结果。对比可以看到，去噪后样本分布整体更接近干净数据的主结构，离散噪声点明显减少。

从指标上看：

1. $\mathrm{MSE}(\mathrm{clean}, \mathrm{denoised})$ 小于 $\mathrm{MSE}(\mathrm{clean}, \mathrm{noisy})$，说明重建后的误差下降；
2. 各特征与干净数据的相关系数在去噪后普遍提升，说明有效信息保留更好；
3. 前两个主成分解释了主要方差信息，因此取 2 维重建在本实验中是有效的。

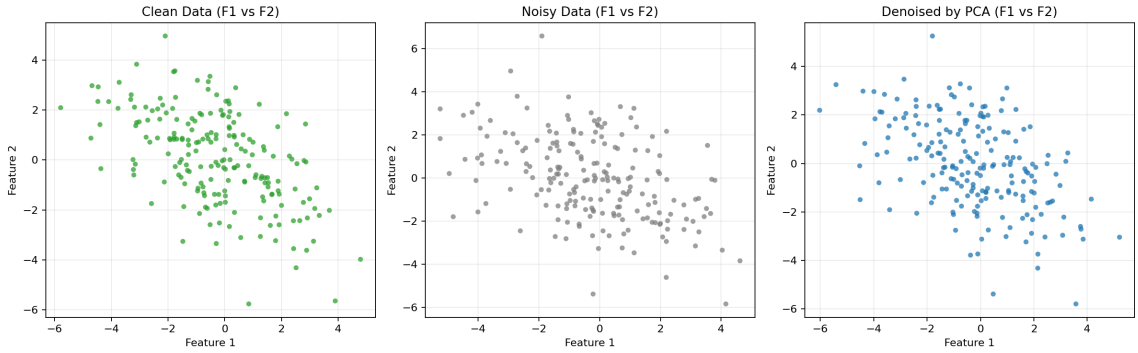

图 1: 干净数据、含噪数据与 PCA 去噪后数据对比（F1-F2 平面）

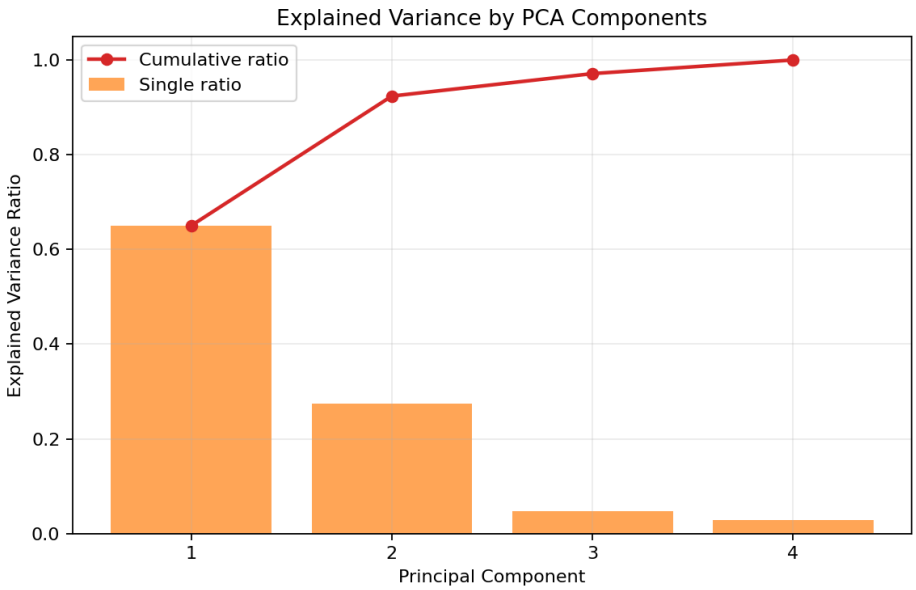

图 2: PCA 各主成分方差贡献率与累计贡献率

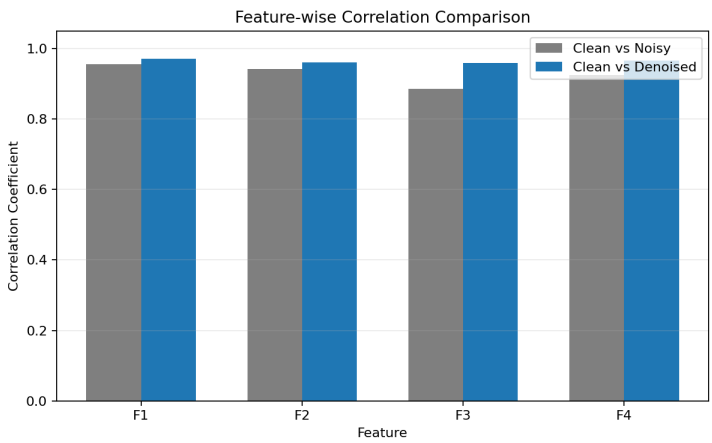

图 3: 各特征相关系数对比（去噪前后）

六、实验总结

本次实验按要求完成了手写 PCA 去噪流程：数据构造、特征分解、降维重建、效果评估和可视化展示。实验结果表明，PCA 在保留主要结构信息的同时，确实能够降低随机噪声带来的干扰。